

African Soil Property Prediction

Ognjen Sretenović, Katarina Jokanović

24. maj 2026.

1 Uvod

Kako bi planiranje izdržive agrikulturalne infrastrukture bilo moguće na mestima o kojima imamo malo podataka, kao što je Afrika, veliki značaj pokazuje digitalno mapiranje funkcionalnih karakteristika zemljišta, kao što su otpornost na eroziju i sadržaj vode i hranljivih materija.

Kao potencijalno značajan, brz i jeftin metod merenja ovih karakteristika pokazuje se *difuzna infracrvena spektroskopija*, kojom se meri interakcija infracrvene radijacije sa materijom, u našem slučaju sa uzorcima zemljišta.

1.1 Podaci

Data set čine podaci o reprezentativnim uzorcima zemljišta sa površine od oko 18 miliona kvadratnih kilometara nepustinjskih delova Afrike i Madagaskara, sakupljenih u okviru *Africa Soil Information Service* projekta.

Uzorci su podeljeni u dve grupe na osnovu dubine - Topsoil (0cm-20cm) i Subsoil (20cm-50cm), i svakom uzorku je dodeljen identifikator.

Imamo 3578 mera apsorpcije na talasnim dužinama u opsegu od $1.3\mu m$ do $16.6\mu m$.

Pored toga, imamo prosečne dugoročne podatke o tropskim padavinama (TMAP, TMFI) i složeni topografski index (CTI).

Od podataka sa *Shuttle Radar Topography* misija imamo podatke o nadmorskoj visini (ELEV) i topografskom reljefu (Reli).

Sa MODIS satelitskih slika imamo dugoročna merenja površinske temperature (LST), prosečna dugoročna *Black-Sky Albedo* merenja (BSA) i prosečna dugoročna merenja refleksije (Ref).

1.2 Izlazna obeležja

Ovim podacima želimo da predvidimo sledeća svojstva zemljišta:

- Ca - Mehlich-3 extractable Calcium
- P - Mehlich-3 extractable Phosphorus
- pH - pH vrednosti
- SOC - Soil organic carbon
- Sand - sadržaj peska

2 Priprema podataka

Iz podataka za treniranje smo izbacili obeležje *PIDN* koje predstavlja identifikator uzorka.

Obeležje *Depth* smo mapirali na numeričke vrednosti (Topsoil $\rightarrow$ 0, Subsoil $\rightarrow$ 1).

2.1 Outlier-i

Jedna od stvari koje smo pokušali jeste izbacivanje outlier-a, međutim time smo gubili skoro trećinu podataka, pa smo odlučili da ograničimo podatke na minimum (vrednost prvog kvartila - $1.5 \cdot$ interkvartilni opseg) maksimum (vrednost trećeg kvartila + $1.5 \cdot$ interkvartilni opseg). Ovo nije uticalo na performanse modela.

2.2 Visoko korelisani podaci

Kako za svaki uzorak imamo 3578 vrednosti apsorpcije po različitim talasnim dužinama očekivali smo da su one u određenoj meri korelisane, što bi uticalo na performanse modela, pa smo odlučili da izbacimo iz data seta podatke sa korelacijom iznad 95%, što nas je ostavilo sa 19 kolona.

Performanse modela nakon ovoga su se uglavnom poboljšale, osim za *KNearestNeighbours* algoritam koji je bez korelisanih kolona dao lošije rezultate.

2.3 Polynomial Features

Svaki algoritam smo trenirali i uz *Polynomial Features* drugog stepena kako bi videli da li kombinacijama atributa možemo pronaći dodatne zakonitosti.

Takođe, ovo smo radili samo na-

kon izbacivanja korelisanih podataka.¹

2.4 Feature Selection

Za dva algoritma, linearnu regresiju koja se pokazala najgora i KNN koji se pokazao najbolje, smo upotreбили i Forward i Backward sekvencijalnu selekciju atributa, što je u oba slučaja dalo lošije rezultate.

3 Algoritmi

3.1 Ocena

Za ocenjivanje regresionih modela koristili smo *Mean Columnwise Root Mean Squared Error*

$$MCRMSE = \frac{1}{5} \sum_{j=1}^5 \sqrt{\frac{1}{n} \sum_{i=1}^n (y_{ij} - \hat{y}_{ij})^2}$$

odnosno prosek korene srednje kvadratne greške po svojstvima koje predviđamo.

3.2 Trening

Svaki model smo trenirali kroz *Grid Search* kros validaciju sa RMSE kriterijumom.

Data set smo podelili na *training set* (80%) i *test set* (20%).

¹Zanimljiva činjenica: *polynomial features* drugog stepena kreirao je 6463810 kolona koje bi zauzele 35.6GB RAM memorije, malo više od onoga što imamo pri ruci

3.3 Modeli

Modeli trenirani algoritmom **linearne regresije** su se pokazali najgore u svim slučajevima.

Modeli trenirani algoritmom **regresionog stabla** su bili bolji.

Random forest algoritmom trenirali smo dva modela, bez koreliranih obeležja sa i bez *polynomial features*-a i njihovi rezultati su blizu najboljim koje smo dobili.

Algoritam **k najbližih suseda - KNN** dao nam je najbolje modele. Takođe, najbolji rezultat je dao na data setu pre izbacivanja visoko koreliranih obeležja.

model	Ca	P	pH	SOC	Sand	MCRMSE
lin_reg	0.505	1.658	0.754	0.705	0.729	0.87
tree	0.565	1.059	0.675	0.53	0.524	0.671
knn	0.371	0.755	0.537	0.464	0.453	0.516
lin_reg_clipped	0.505	1.658	0.754	0.705	0.729	0.87
tree_clipped	0.565	1.059	0.675	0.53	0.524	0.671
knn_clipped	0.371	0.755	0.537	0.464	0.453	0.516
lin_reg_bez_korelacija	0.833	0.699	0.68	0.832	0.77	0.763
tree_bez_korelacija	0.511	0.725	0.616	0.723	0.526	0.62
knn_bez_korelacija	0.679	0.764	0.568	0.629	0.544	0.637
random_forest_bez_korelacija	0.516	0.866	0.508	0.559	0.419	0.573
lin_reg_bez_korelacija_pol	0.642	0.699	0.619	0.766	0.671	0.679
tree_bez_korelacija_pol	0.511	0.725	0.616	0.723	0.526	0.62
knn_bez_korelacija_pol	0.679	0.764	0.568	0.629	0.544	0.637
random_forest_bez_korelacija_pol	0.528	0.922	0.504	0.567	0.416	0.588
lin_reg_bez_korelacija_selection	0.828	0.692	0.682	0.858	0.801	0.772
knn_bez_korelacija_selection	0.582	0.687	0.537	0.605	0.413	0.565

Tabela 1: Ocene modela po izlaznim obeležjima

4 Primena modela

Nakon treninga svakog modela na ranije pomenuti način izdvojali smo parametre sa kojima model daje najbolje rezultate i sa njima ponavljali trening, ovaj put na celom data setu.

Ovako trenirane finalne modele koristili smo za predviđanje na osnovu podataka iz *sorted_test* data seta i rezultate predavali na kaggle.

Ocena prvog modela linearne regresije koji smo kreirali bila je 1.08, a ocena najboljeg KNN modela 0.74.

	prediction_lin_reg.csv Complete (after deadline) · 4d ago · Prediction using linear regression	0.93135	1.08306
---	--	----------------	----------------

Slika 1: kaggle score - linearna regresija

Submission and Description		Private Score 	Public Score 
	knn.csv Complete (after deadline) · 3m to go · Predictions using knn	0.71811	0.74375

Slika 2: kaggle score - knn

5 Zaključak i budući pravci

Na kraju se osećamo malo nezadovoljno činjenicom da se nakon svog truda najbolje pokazao običan KNN.

Žao nam je i što zbog hardware-skih ograničenja nismo mogli da treniramo modele primenom *Boosting* algoritama, treniramo Random Forest model i primenimo *Sequential Feature Selection* na data setu pre izbacivanja visoko koreliranih kolona.

Literatura

- [1] Africa Soil Information Service (AfSIS) — isric.org. <https://isric.org/projects/africa-soil-information-service-afsis>. [Accessed 24-05-2026].
- [2] Africa Soil Property Prediction Challenge — kaggle.com. <https://www.kaggle.com/competitions/afsis-soil-properties>. [Accessed 23-05-2026].
- [3] API Reference — scikit-learn 1.8.0 documentation - sklearn — sklearn.org. <https://sklearn.org/stable/api/index.html>. [Accessed 24-05-2026].
- [4] Infrared spectroscopy - Wikipedia — en.wikipedia.org. https://en.wikipedia.org/wiki/{I}nfrared_spectroscopy. [Accessed 24-05-2026].
- [5] MODIS Web — modis.gsfc.nasa.gov. <https://modis.gsfc.nasa.gov/>. [Accessed 24-05-2026].
- [6] OpenTopography - Shuttle Radar Topography Mission (SRTM GL1) Global 30m — portal.opentopography.org. <https://portal.opentopography.org/raster?opentopo{I}{D}={0}{T}{S}{R}{T}{M}.082015.4326.1>. [Accessed 24-05-2026].
- [7] Reflectance Infrared (FT-IR) Spectroscopy — bruker.com. <https://www.bruker.com/en/products-and-solutions/infrared-and-raman/ft-ir-routine-spectrometer/what-is-ft-ir-spectroscopy/reflectance-infrared-spectroscopy.html>. [Accessed 24-05-2026].
- [8] Shuttle Radar Topography Mission (SRTM) — NASA Earthdata — earthdata.nasa.gov. <https://www.earthdata.nasa.gov/data/instruments/srtm>. [Accessed 24-05-2026].
- [9] Topographic wetness index - Wikipedia — en.wikipedia.org. https://en.wikipedia.org/wiki/{T}opographic_wetness_index. [Accessed 24-05-2026].
- [10] Vegetation index - Wikipedia — en.wikipedia.org. https://en.wikipedia.org/wiki/{V}egetation_index. [Accessed 24-05-2026].
- [11] XGBoost Documentation — xgboost 3.2.0 documentation — xgboost.readthedocs.io. https://xgboost.readthedocs.io/en/release_2.1.0/. [Accessed 24-05-2026].